校园智测——基于 GLM 的校园智能体全方位质量保障实践

> 传智杯「AI赋能.智能测试创新挑战赛」路径一参赛作品 · 作品介绍文档 参赛路径：路径一（智能体应用的全方位测试，侧重测试方案设计与执行） 参赛队：蹦蹦炸弹　指导老师：廖丽平

一、项目详情及使用方式

1.1 项目背景

AI 智能体的自主性（规划、工具调用、记忆、RAG）带来了传统软件测试无法覆盖的质量风险：检索到错误知识给出错误建议、多步执行中"迷路"、被诱导执行非预期操作、工具异常时编造数据。本项目完整实践了"**先造后测**"的赛题要求：先自研搭建一个真实可用的校园智能体应用，再围绕它的全链路设计并执行系统性测试。

1.2 被测对象：云帆小帆校园智能助手

项	说明
目标用户	云帆大学全校学生（以本科生为主），覆盖新生入学高频疑问场景
核心能力	① 制度问答（RAG）：校历、学籍、选课、成绩、奖助、宿舍、图书馆等 10 篇制度文件；② 教务工具调用：成绩单/周课表查询（含错误转述）；③ 任务规划：复合指令串联工具→推理→检索→结论；④ 多轮对话记忆：指代消解、信息保持、修正跟踪
技术栈	智谱 GLM（glm-4.6 对话 + glm-4.5-air 评审）+ 自研 Agent 循环（OpenAI function-calling 协议）+ BM25 检索（字符二元组，免分词依赖）+ FastAPI（接口与 Dify Service API 同构）
安全设计	系统提示词 7 条护栏（提示词层）+ 输入侧写作任务结构性拦截（代码层）

系统架构见 `reports/figures/architecture.png` 。

1.3 使用方式与操作演示

```
 pip install -r requirements.txt
cp .env.example .env            # 填入智谱 API Key
python -m uvicorn scripts.mock_tools_api:app --port 8901   # 终端1：模拟教务API
python agent-app/campus_agent.py serve                     # 终端2：智能体服务 :8902
```

浏览器打开 `http://127.0.0.1:8902/demo` 即进入聊天演示界面（v2：头像/时间戳/打字动画/工具调用轨迹卡片/Markdown 表格渲染）： - 制度问答演示：提问"国家奖学金一年多少钱"，助手

调用检索工具后给出准确答案（8000 元/年、比例 0.2%、条件前 10%），界面同时展示工具调用轨迹徽章：



- 工具调用演示：查询指定学号学期成绩，助手抽取参数调用 query_score 并将返回数据整理成表格转述：



讲解视频（含智能体实际表现、测试执行过程与工具操作流程，5 分 12 秒）：https://www.bilibili.com/video/BV1KMsf6uEEB/ 除图形界面外，支持命令行问答（`python agent-app/campus_agent.py ask "问题"`，同步打印工具轨迹）、REST API 调用与全量自动化测试（`pytest tests/`，218 条用例）。

二、项目亮点（方法论：「三层分锥 • 轨迹断言」测试法 + 七维靠谱度评分卡）

我们把整个测试方法提炼为**「三层分锥·轨迹断言」测试法**：断言对象从"最终输出"下沉到"思维链路轨迹"，评估产出收敛为一张**七维度加权的靠谱度评分卡**。与传统软件测试的本质差异：

对比项	传统软件测试	本方法（智能体测试）
断言对象	输出值/状态	**工具调用轨迹 + 检索内容 + 最终答案**三层
通过标准	确定性二值断言	关键数字强断言 + **LLM 三元判定（1/0.5/0）** + 轨迹断言组合
用例设计	等价类/边界值	增加四组件专属设计：规划复合指令、记忆跨轮脚本、RAG 拒答/**故意埋冲突语料**、安全攻击库
判定器	无需判定器	LLM-as-a-Judge，**双判定器一致性校准 + 与被测模型异构隔离**
缺陷根因	代码逻辑	五分类：提示词/检索/模型能力/知识库质量/工具接口
评测体系自身	—	用例变异扩写抽审、框架缺陷台账（11 项）——"测 AI 的体系"也要被验证

六大具体亮点：

1. **评审四组件全覆盖**：规划（8 条复合任务，含"查成绩→对照国奖条件→诚实告知不满足"的诚实性场景）、记忆（20 条多轮脚本 + 长对话边界探针）、工具调用（30 条轨迹断言）、RAG（40 条 + RAGAS 量化）——每个组件都有专属测试模块与量化指标。
2. **工具调用轨迹级断言**：验证"该不该调、调的对不对、参数对不对、异常怎么转述"，包括"信息不足应澄清而非虚构参数调用""参数非法时前置校验优于盲目调用"等智能体特有断言语义。
3. **知识库冲突治理测试**：故意埋设 2 处新旧版本冲突（退课截止周、熄灯时间），验证冲突识别与"以最新制度为准"。
4. **「提示词防御不可靠」实证**：文书代写越界请求经两轮提示词加固均失败，输入侧结构性护栏根治，35 条安全用例回归零副作用——为智能体安全分层防护提供实测依据。
5. **量化与用例互补的评估观**：RAGAS faithfulness=0.728（召回 0.929/精确率 0.879）与用例级"零编造"结论的差异，被归因为"模型主动转介建议"与忠实度指标的天然张力——证明量化指标与用例断言应互补而非互替。
6. **测试资产自身的质量管控**：初测 15 个失败中 11 个定位为测试框架缺陷并全部修复留档；36 条 LLM 变异用例 100% 抽审通过；全程证据链（218 份用例 JSON + 8 轮结果 CSV）可审计可复现。

> 注：35 条对抗用例均为**预防性红队测试**——以假设性提问验证智能体的拒绝与引导能力（期望行为=明确拒绝并说明后果），用例本身不构成对越狱、赌博、作弊等行为的任何指导，属安全测试的正向防御实践（映射 OWASP LLM Top 10）。

三、AI 能力应用说明

3.1 智能体搭建中的 AI 应用

- **提示词设计**：五段式结构（角色/能力边界/回答规范/7 条安全护栏/多轮规范），完整样例见 `agent-app/系统提示词.md`；
- **工作流编排**：自研 Agent 循环"输入护栏预检 → LLM 决策 → 工具执行 → 结果回填 → 再决策"闭环（≤6 轮），每一步可观测可断言；
- **工具配置**：三个工具以 OpenAI function-calling Schema 声明，参数约束（学号 10 位、周次 1-20、学期枚举）下沉到工具协议层。

3.2 测试环节中的 AI 应用（人机协同流程）

环节	AI 应用	人的角色
用例生成	LLM 变异扩写 36 条（同义/口语化/噪声/场景化），自动抽审 100% 通过（docs/06）	设计种子用例与期望、最终抽认
结果判定	LLM-as-a-Judge 五套判定提示词；**双判定器（4.5-air vs 4.6）30 样本一致性 100%**，判定器与被测模型异构隔离防偏袒	分歧样本仲裁
量化评估	RAGAS（Faithfulness/ContextPrecision/ContextRecall），评估 LLM 指向 GLM	指标口径定义与解读
缺陷归因	LLM 辅助五分类归因	确认根因、设计修复实验

四、关键技术说明

架构图：`reports/figures/architecture.png`；**测试体系图**：`reports/figures/test_pyramid.png`；**测试方案**：docs/01；**七维雷达图与评分卡**：`reports/figures/radar.png`、`reports/靠谱度评分卡.md`。

核心代码片段——输入侧结构性护栏（缺陷 D-02 最终修复）：

```
WRITING_GUARD = re.compile(
  r"(写|代写|起草|创作|帮我生成).{0,10}(申请书|检讨书|请假条|论文|作文|演讲稿|发言稿|个人陈述|故事)"
  r"|(申请书|检讨书|请假条|论文|作文|演讲稿|发言稿|个人陈述).{0,12}(模板|范文|格式|怎么写|如何写|范例)", re.S)
# 命中则直接返回边界说明与流程指引，不进入大模型；"写文书"与"问流程"正则区分
```

核心代码片段——规划维度断言（`tests/test_07_planning.py`）：

```
for t in case["required_tools"].split(";"):       # 复合指令必须出现完整工具链
  if t not in texts: errors.append(f"规划缺失工具调用: {t}")
missed = [n for n in case["strict_numbers"].split("|") if norm(n) not in norm(answer)]
```

Prompt 设计样例：`agent-app/系统提示词.md`（系统提示词全量）、`tests/judge/llm_judge.py`（五套 Judge 判定提示词）。

五、项目相关图片/截图

图	说明
`reports/figures/demo_rag问答.png` / `demo_工具调用.png`	智能体交互界面实拍：制度问答（检索工具轨迹）与成绩查询（表格化转述）
`reports/figures/demo_规划任务.png` / `demo_安全拦截.png`	复合任务规划（多轮记忆+双工具链）与写作护栏拦截实拍
`reports/figures/pytest执行截图.png`	**测试执行过程截图**（全量 pytest 运行实录节选，211 条 1h20m）
`reports/figures/architecture.png` / `test_pyramid.png`	系统架构图 / 三层测试体系图
`reports/figures/radar.png`	七维度通过率雷达图（终态 100%）
`reports/pytest_full_run.log`	全量执行日志（1h20m）
`reports/data/*.csv` 、 `reports/靠谱度评分卡.md`	各轮结果、RAGAS、校准、压测数据与测试报告样例（评分卡）

六、项目过往发表或获奖情况说明

无。

七、优化说明

本项目为原创作品。模拟教务 API 与自研 Agent 循环参考 FastAPI 与 OpenAI SDK 官方公开接口规范自行实现；工具轨迹解析参考 Dify Service API 公开响应结构以保持平台兼容。无对既有项目代码的复用。

附：测试结果总览（七大质量维度 + 性能）

维度	用例数	初测通过	终态通过
功能准确性	60	56	60
任务规划	8（第7轮补测）	—	8
工具调用	30	24	30
RAG 检索质量	40	39	40
多轮对话	20	19	20
对抗与安全	35	34	35
边界与异常	25	23	25

维度	用例数	初测通过	终态通过
合计	**218**	**195/209*（93.3%）**	**218（100%）**

> * 初测阶段规划维度 8 条尚未设计（第 7 轮补测），初测分母为当时 210 条黄金中的 209 条有效记录（S13 环境瞬断未入账，复测通过另计）；终态分母为 218。

另：AI 变异扩展用例 36/36 通过；RAGAS 忠实度 0.728 / 上下文召回 0.929 / 上下文精确率 0.879（口径与归因见缺陷报告 §5）；性能 3 并发 P95=13s 零错误，容量瓶颈在上游模型 API 配额（缺陷报告 §8）。

附：实用性与推广（迁移指南）

- **平台迁移低成本（设计对齐，未实测）**：被测服务接口结构与 Dify Service API 同构（/v1/chat-messages、conversation_id、metadata.tool_calls），测试套件按平台无关方式编写，切换 `.env` 的 `DIFY_BASE_URL` 即可指向 Dify 应用；因本机网络无法访问 cloud.dify.ai（DNS 污染 + IP 阻断），该迁移路径未在真实 Dify 实例上实测，属设计性声明；
- **场景迁移低成本**：知识库语料、黄金用例集、攻击库均为数据文件，替换为其他领域（法律/医疗/客服）语料与用例即可复用整套测试框架；
- **潜在落地**：高校信息中心智能体验收测试、Agent 开发团队的持续回归门禁、教务/门户系统厂商的出厂质检。